Alma Mater Studiorum · Università di Bologna

DIPARTIMENTO DI INFORMATICA - SCIENZA E INGEGNERIA
Corso di Laurea Triennale in Ingegneria e scienze informatiche

Intelligent Reflecting Surfaces

Progettazione, modellazione e ottimizzazione

Tesi di Laurea in Ingegneria e Scienze Informatiche

Relatore:
Chiar.mo Prof.
Andrea Piroddi

Presentata da:
Alessandro Rebosio

Sessione di Laurea I
Anno Accademico 2025/2026

Qui ci va la dedica/citazione

Introduzione

Negli ultimi anni l'evoluzione delle reti di comunicazione wireless ha conosciuto una crescita rapida e diffusa, alimentata dalla domanda di connettività ad alta velocità, da requisiti di bassa latenza e dal consistente aumento del numero di dispositivi connessi. Le reti di quinta generazione (5G) hanno rappresentato un salto qualitativo significativo, contribuendo al raggiungimento di ambiziosi obiettivi di capacità almeno mille volte superiore alle tecnologie precedenti e connettività ubiqua per decine di miliardi di dispositivi. Questo risultato è stato reso possibile dall'impiego di soluzioni tecnologiche avanzate, quali il Multiple-Input Multiple-Output Massivo (Massive MIMO), le comunicazioni in banda millimetrica (mmWave) e le reti ultra-dense (Ultra Dense Networks, UDN).

Nonostante i significativi benefici apportati, le reti 5G continuano a presentare criticità rilevanti legate alla complessità hardware, ai costi di implementazione e al consumo energetico. In particolare, l'estensione del Massive MIMO dalle bande sub-6 GHz alle frequenze millimetriche richiede architetture altamente complesse, maggior numero di catene a radiofrequenza (RF) e hardware sofisticato e costoso dal punto di vista energetico. Parallelamente, la propagazione in banda mmWave risulta fortemente penalizzata dalla vulnerabilità al blocco indoor e dai fenomeni di attenuazione, rendendo difficile mantenere livelli affidabili di copertura e qualità del segnale.

In questo contesto, il paradigma tradizionale di adattamento basato esclusivamente sulla progettazione del trasmettitore e del ricevitore mostra limitazioni crescenti, motivando un ripensamento radicale dell'ambiente di propagazione. Le Intelligent Reflecting Surfaces (IRS) emergono come una tecnologia promettente per riconfigurare in modo intelligente l'ambiente di propagazione mediante il controllo di elementi riflettenti passivi a basso costo. Questo approccio introduce un nuovo grado di libertà nella gestione

del canale radio, permettendo di migliorare copertura, efficienza spettrale ed energetica e di mitigare fading e interferenza con costi di implementazione contenuti rispetto alle soluzioni tradizionali.

L'integrazione delle IRS in sistemi Massive MIMO e in scenari 5G e oltre-5G comporta tuttavia sfide tecniche significative e ancora largamente inesplorate. Queste includono la modellazione accurata del canale in presenza di superfici riflettenti passive, la progettazione congiunta dei beamforming attivi e passivi, l'acquisizione affidabile della CSI negli scenari multiutente e dinamici, e la gestione della complessità computazionale intrinseca in tali sistemi ibridi. La natura non convessa di molti problemi di ottimizzazione derivanti dalla struttura moltiplicativa dei canali assistiti da IRS, unita alla necessità di adattamento continuo a condizioni di propagazione variabili, rende inadeguati gli approcci puramente analitici tradizionali.

In questa prospettiva, le tecniche di Machine Learning rappresentano strumenti potenti e versatili per affrontare la complessità dimensionale e la non-linearità di reti assistite da IRS. In particolare, possono supportare l'ottimizzazione adattiva dei coefficienti di riflessione e, più in generale, il controllo della superficie sulla base di indicatori di prestazione osservati.

L'obiettivo principale di questa tesi è proporre e valutare un quadro metodologico per l'analisi delle reti wireless assistite da IRS mediante tecniche di Machine Learning, con particolare attenzione alla modellazione del problema, agli algoritmi di apprendimento, e alla validazione mediante simulazioni. In particolare, il lavoro si concentra sul controllo dinamico delle IRS in scenari indoor, evidenziando modello, metriche e metodologia sperimentale.

Indice

Introduzione **ii**

1 Contesto, motivazione e obiettivi **1**
1.1 Problemi di copertura indoor nelle reti wireless 1
1.2 Limiti delle soluzioni tradizionali 2
1.3 Intelligent Reflecting Surfaces: idea di base 2
1.4 Obiettivi e contributi della tesi 3

2 Fondamenti teorici **4**
2.1 Propagazione radio in ambiente indoor 4
2.2 Principio di funzionamento delle IRS 5
2.2.1 Motivazione per approcci basati su Machine Learning 6
2.3 Modello di canale assistito da IRS 7
2.3.1 Modellazione dei canali 7
2.3.2 Problema di ottimizzazione 8

3 Scenario di riferimento e modello di simulazione **9**
3.1 Descrizione dello scenario 9
3.2 Modello di sistema 10
3.3 Assunzioni semplificative 11
3.4 Metriche di valutazione 12
3.4.1 Formulazione RL per il controllo delle fasi IRS 13

4 Formulazione del problema di controllo IRS **14**
4.1 Formulazione del problema di controllo 14
4.2 Ingresso al sistema di Machine Learning 15
4.2.1 Posizione utente 15
4.2.2 CSI semplificato 16
4.3 Output: configurazione di fase IRS 16
4.4 Vincoli pratici 17
4.4.1 Quantizzazione discreta della fase 17

4.4.2 Numero di elementi e complessità 17
4.4.3 Modulo di riflessione unitario 17
4.4.4 Latenza di riconfigurazione 17
4.4.5 Scalabilità a IRS di grandi dimensioni 18

5 Algoritmi di Machine Learning considerati 19
5.1 Regressione multivariata 19
5.2 k-Nearest Neighbors 20
5.3 Multi-Layer Perceptron (MLP) 21
5.4 Confronto tra modelli: 22
5.4.1 Accuratezza 23
5.4.2 Complessità 24
5.4.3 Stabilità 25

Capitolo 1

Contesto, motivazione e obiettivi

1.1 Problemi di copertura indoor nelle reti wireless

Negli ambienti indoor la copertura radio presenta sfide significative rispetto agli scenari outdoor a causa della complessità geometrica e dei materiali costruttivi. Le onde elettromagnetiche incontrano pareti, pavimenti, soffitti, mobili e altre superfici che causano attenuazione di penetrazione (penetration loss) variabile con la frequenza e con la tipologia di materiale; materiali come calcestruzzo, vetro stratificato o metallo possono introdurre perdite elevate e creare "zone d'ombra" attorno a sorgenti di segnale.

Un altro fenomeno critico è il multipath: il segnale trasmesso arriva al ricevitore attraverso molteplici percorsi dovuti a riflessioni, diffrazioni e scattering. Questa ricombinazione di contributi può generare fading su piccola scala, variazioni rapide dell'ampiezza e della fase del segnale, e allungamento temporale dell'impulso (delay spread) che peggiora la qualità del collegamento e aumenta la probabilità di errori nella ricezione.

La dipendenza dalla frequenza è particolarmente rilevante nelle bande mmWave: sebbene forniscano ampia larghezza di banda e alte capacità, presentano elevata attenuazione in presenza di ostacoli e sono fortemente sensibili al blocco da parte di elementi mobili (persone, porte) e fissi (mobili metallici). Questo rende la copertura mmWave in ambienti indoor molto non uniforme e suscettibile a interruzioni frequenti.

La mobilità degli utenti e la presenza di ostacoli dinamici introducono ulteriori difficoltà: link temporaneamente Non in Linea di Vista (NLoS) possono degradare drasticamente le prestazioni, richiedendo procedure di riconvergenza, ri-allineamento dei fasci

(beam alignment) o handover verso altre celle o punti di accesso.

Queste problematiche motivano l'adozione di approcci che agiscono direttamente sull'ambiente di propagazione, anziché limitarsi a ottimizzare esclusivamente trasmettitore e ricevitore. Le Intelligent Reflecting Surfaces (IRS) si inseriscono in questo contesto come possibile soluzione per riconfigurare il campo elettromagnetico in modo passivo e a basso costo, migliorando copertura e affidabilità in ambienti indoor complessi. [7]

1.2 Limiti delle soluzioni tradizionali

Le soluzioni tradizionali (aumento di potenza, densificazione, antenne direzionali e Massive MIMO) presentano limiti rilevanti. L'aumento di potenza è vincolato da normative e inefficienze energetiche; la densificazione comporta costi elevati, complessità di gestione e maggiore interferenza. Le architetture Massive MIMO, sebbene efficaci, richiedono numerose catene RF e introducono elevata complessità nell'acquisizione dell'Informazione sullo Stato del Canale (Channel State Information, CSI), soprattutto alle frequenze mmWave dove sensibilità al blocco e attenuazione sono più pronunciate [6, 7, 1].

Inoltre, molte soluzioni si concentrano esclusivamente su trasmettitore e ricevitore trascurando la possibilità di intervenire sull'ambiente di propagazione. Questo approccio mostra limiti crescenti quando la geometria degli spazi e i materiali causano penetrazioni e riflessioni complesse (tipiche degli scenari indoor), riducendo l'efficacia di metodi che si limitano a parametri lato stazione base o terminale.

1.3 Intelligent Reflecting Surfaces: idea di base

Le Intelligent Reflecting Surfaces (IRS) propongono un paradigma diverso rispetto alle soluzioni tradizionali: invece di limitarsi a ottimizzare i nodi trasmissivi, si modifica attivamente l'ambiente di propagazione mediante superfici passive composte da un elevato numero di elementi elementari riconfigurabili. Ogni elemento può introdurre uno sfasamento (e, in alcune implementazioni, variazioni di ampiezza) al segnale incidente, permettendo di realizzare un beamforming passivo che ridistribuisce energia verso regioni d'interesse senza richiedere catene RF attive per ogni elemento [10, 2].

Dal punto di vista del controllo, il nucleo del problema è la scelta dei coefficienti di riflessione per gli elementi IRS in modo da massimizzare metriche quali potenza ricevuta,

Rapporto Segnale-Rumore (Signal-to-Noise Ratio, SNR) o probabilità di copertura. La modellazione del canale in presenza di IRS introduce termini moltiplicativi che accrescono la non-convessità dei problemi di ottimizzazione e la complessità computazionale delle soluzioni classiche. Per questi motivi, le soluzioni basate su metodi euristici, ottimizzazione alternata e tecniche data-driven sono state proposte nella letteratura recente.

1.4 Obiettivi e contributi della tesi

Lo scopo di questo lavoro è sviluppare e valutare un metodo di controllo delle fasi basato su tecniche di Machine Learning per Intelligent Reflecting Surfaces (IRS) in scenari indoor. Il lavoro prevede la simulazione di un ambiente interno realistico e l'uso di algoritmi di apprendimento automatico (semplici e interpretabili) per stimare, a partire dalla posizione dell'utente, la configurazione di fase degli elementi IRS che massimizza la copertura e la potenza ricevuta. L'obiettivo finale è quantificare il guadagno di copertura e la robustezza ottenibili grazie all'IRS rispetto a configurazioni senza IRS o non ottimizzate, analizzando prestazioni in scenari multiutente e con canali tipici di bande mmWave. In sintesi, i contributi principali consistono nella definizione del modello di sistema, nella formulazione del problema di controllo e nella valutazione comparativa delle prestazioni.

Capitolo 2

Fondamenti teorici

2.1 Propagazione radio in ambiente indoor

Per modellare la propagazione radio indoor si adotta il modello di *basic transmission loss* raccomandato dall'International Telecommunication Union - Radiocommunication Sector (ITU-R) P.1238 [7] per collegamenti base station–utente all'interno dello stesso edificio. In particolare, per scenari in cui trasmettitore e ricevitore si trovano sullo stesso piano, la perdita di percorso mediana è espressa come:

$$L_b(\mathbf{d}, \mathbf{f}) = \mathbf{A} + 10\,\mathbf{n}\log_{10}(\mathbf{d}) + \mathbf{B}\log_{10}(\mathbf{f}) + \mathbf{X}_\sigma \quad [\text{dB}] \tag{2.1}$$

dove $\mathbf{d}$ è la distanza tridimensionale tra trasmettitore e ricevitore (in metri), $\mathbf{f}$ la frequenza operativa (in GHz), $\mathbf{n}$ l'esponente di perdita di percorso, $\mathbf{A}$ e $\mathbf{B}$ coefficienti che modellano rispettivamente l'offset e la dipendenza dalla frequenza, mentre $\mathbf{X}_\sigma$ è una variabile aleatoria gaussiana a media nulla e deviazione standard $\boldsymbol{\sigma}$ che rappresenta lo **shadow fading** log-normale. I valori di $\mathbf{A}$, $\mathbf{n}$, $\mathbf{B}$ e $\boldsymbol{\sigma}$ sono forniti da ITU-R P.1238 per diversi ambienti (ufficio, corridoio, industriale, sala conferenze) e per condizioni In Linea di Vista (Line of Sight, LoS)/NLoS; nel presente lavoro si adotta la configurazione "office NLoS" nel range di distanza e frequenza coerente con le simulazioni assistite da IRS.

Oltre alla perdita di percorso media, l'ambiente indoor è caratterizzato da **multipath** dovuto a riflessioni, diffrazioni e scattering su pareti, soffitti, pavimenti e arredo, che genera variazioni rapide di ampiezza e fase del segnale e un allungamento temporale dell'impulso. La risposta impulsiva del canale può essere descritta tramite il **power**

delay profile, da cui si ricava il **delay spread a media quadratica (root mean square, r.m.s.)** $\boldsymbol{\tau}_{\mathrm{rms}}$, che per ambienti d'ufficio tipici assume valori mediani compresi tra alcune decine e alcune centinaia di nanosecondi, con variazioni dipendenti da frequenza, dimensioni del locale e larghezza di banda angolare delle antenne. In linea con i dati riportati in ITU-R P.1238, per il caso di ufficio indoor si considera un delay spread r.m.s. dell'ordine di **50–150** ns (valori di Tabella 7 per ambienti "office" nelle bande GHz di interesse) e una deviazione standard dello shadow fading di circa 3–6 dB, a seconda della specifica combinazione ambiente/frequenza.

2.2 Principio di funzionamento delle IRS

Le *Intelligent Reflecting Surfaces* (IRS) sono metasuperfici planari con M elementi riconfigurabili (unit cells), spesso disposti su una griglia $N \times N$ con $M = N^2$ [2]. Ogni elemento modifica in modo controllato il segnale incidente; a differenza di una superficie riflettente passiva tradizionale, il comportamento elettromagnetico si può regolare in tempo reale tramite componenti come diodi PIN o varattori, senza catene RF attive per elemento.

Il comportamento dell'elemento $m = 1, \ldots, M$ si descrive con il coefficiente di riflessione complesso:

$$\Gamma_m = \beta_m e^{j\theta_m}, \tag{2.2}$$

dove $\theta_m \in [0, 2\pi)$ è la fase controllabile e $\beta_m \in [0, 1]$ rappresenta l'attenuazione dovuta a perdite di inserzione ($\beta_m \approx 0.9$–1 per implementazioni state-of-the-art).

Il principio fisico è il *beamforming passivo*: scegliendo le fasi $\{\theta_m\}_{m=1}^{M}$ in modo coerente, i contributi riflessi si sommano verso una direzione o una posizione obiettivo, aumentando il campo ricevuto nel regime far-field con un guadagno che cresce con M. Questo crea un cammino Stazione Base (Base Station, BS)–IRS–Equipaggiamento Utente (User Equipment, UE) controllabile, utile quando il collegamento diretto è indebolito da ostacoli indoor.

Nella pratica entrano tre vincoli: la quantizzazione della fase, perché θ_m assume pochi livelli discreti (es. 2–3 bit, $K = 4$–8 livelli) per semplificare l'hardware [2]; l'overhead di configurazione, dato che le fasi sono impostate dal controller IRS (via backhaul dalla BS)

con latenza dell'ordine dei ms; e la dipendenza dalla posizione, per cui la configurazione ottima $\mathbf{\Theta}^\star = \arg\max_{\mathbf{\Theta}} P_r(\mathbf{p})$ varia con la posizione utente $\mathbf{p}$.

2.2.1 Motivazione per approcci basati su Machine Learning

Il problema di ottimizzazione delle fasi IRS per massimizzare la potenza ricevuta $P_r(\mathbf{p})$ o metriche correlate (SNR, copertura) presenta sfide computazionali significative. La struttura moltiplicativa del canale assistito da IRS, discussa in sezione 2.3, introduce termini non-convessi che rendono inadeguati metodi di ottimizzazione locale classici, i quali possono convergere a minimi locali subottimali. Tecniche come l'ottimizzazione alternata o i metodi di rilassamento semidefinito (Semidefinite Relaxation, SDR) forniscono soluzioni approssimate ma richiedono tempi di calcolo proibitivi per sistemi con elevato numero di elementi ($M \gg 100$) e aggiornamenti frequenti.

Inoltre, la dipendenza dalla posizione $\mathbf{p}$ implica che la matrice di configurazione ottima $\mathbf{\Theta}^\star(\mathbf{p})$ deve essere ricalcolata continuamente al variare della posizione utente, rendendo impraticabile l'uso di ottimizzazione iterativa in scenari dinamici o con mobilità elevata. Per questi motivi, approcci *data-driven* basati su Machine Learning rappresentano una alternativa promettente: un modello addestrato su dataset di coppie $(\mathbf{p}, \mathbf{\Theta}^\star)$ generati tramite simulazioni di canali indoor realistici può apprendere la mappatura $\mathbf{p} \mapsto \{\theta_m\}$ in modo efficiente, fornendo previsioni in tempo reale con complessità computazionale ridotta rispetto a metodi iterativi. Nel presente lavoro si esplorano algoritmi semplici e interpretabili (regressione, alberi decisionali, reti neurali compatte) per stimare la configurazione di fase ottimale a partire dalle coordinate (x, y) dell'utente, valutando il guadagno di copertura ottenuto in ambienti indoor caratterizzati da propagazione multipath e blocco.

2.3 Modello di canale assistito da IRS

In uno scenario assistito da IRS, il collegamento tra BS e UE è mediato dalla superficie riflettente. Supponendo che la BS trasmetta con potenza P_t e che il canale presenti attenuazione di percorso su due tratte (BS→IRS e IRS→UE), si ottiene un modello a due hop per la potenza ricevuta, coerente con i canali cascaded BS-IRS-UE proposti [4].

Sia $\mathbf{h}_{\mathrm{BI}} \in \mathbb{C}^M$ il vettore di canale tra BS e gli M elementi IRS, e sia $\mathbf{h}_{\mathrm{IU}} \in \mathbb{C}^M$ il vettore di canale tra IRS e UE. Il canale complessivo BS→IRS→UE si esprime come:

$$h_{\mathrm{eff}} = \mathbf{h}_{\mathrm{IU}}^H \operatorname{diag}(\boldsymbol{\Gamma})\, \mathbf{h}_{\mathrm{BI}}, \tag{2.3}$$

dove $\boldsymbol{\Gamma} = [\Gamma_1, \ldots, \Gamma_M]^T$ è il vettore dei coefficienti di riflessione (2.2), e $\operatorname{diag}(\boldsymbol{\Gamma})$ è la matrice diagonale con gli Γ_m sulla diagonale (cfr. modello $\mathbf{H}_{I,k} = \mathbf{G}^T \operatorname{diag}(\mathbf{h}_{r,k})$ per casi MISO in [4]). Assumendo per semplicità $\beta_m = 1$ (riflessione ideale senza perdite resistive), si ha $\boldsymbol{\Gamma} = e^{j\boldsymbol{\theta}}$ con $\boldsymbol{\theta} = [\theta_1, \ldots, \theta_M]^T$.

2.3.1 Modellazione dei canali

Per modellare i vettori di canale $\mathbf{h}_{\mathrm{BI}}$ e $\mathbf{h}_{\mathrm{IU}}$, si adotta un modello geometrico semplificato coerente con la propagazione indoor descritta nella Sezione 2.1 e con scenari sub-6 GHz non-sparsi in [4]. In particolare, ogni elemento di canale $h_{\mathrm{BI},m}$ e $h_{\mathrm{IU},m}$ include:

- **Path loss**: calcolato mediante (2.1) in funzione della distanza $d_{\mathrm{BI},m}$ (BS→elemento m) e $d_{\mathrm{IU},m}$ (elemento m→UE), con parametri ambiente-specifici [7];
- **Shadow fading**: termine gaussiano log-normale X_σ con deviazione standard tipica 3–6 dB;
- **Small-scale fading**: fase uniforme in $[0, 2\pi)$ per simulare multipath in regime narrowband o OFDM su sottoportante singola.

Questo modello cattura la geometria dell'ambiente e l'effetto della posizione utente $\mathbf{p}$ sui percorsi riflessi.

La potenza ricevuta via IRS è quindi:

$$P_r(\mathbf{p}, \boldsymbol{\theta}) = P_t \left| h_{\mathrm{eff}}(\mathbf{p}, \boldsymbol{\theta}) \right|^2. \tag{2.4}$$

2.3.2 Problema di ottimizzazione

Il problema di ottimizzazione consiste nel determinare $\boldsymbol{\theta}^\star(\mathbf{p})$ che massimizza (2.4):

$$\boldsymbol{\theta}^\star(\mathbf{p}) = \arg \max_{\boldsymbol{\theta} \in [0,2\pi)^M} P_r(\mathbf{p}, \boldsymbol{\theta}), \tag{2.5}$$

soggetto ai vincoli di quantizzazione (fasi discrete a K livelli) e ai limiti hardware. La non-convessità di (2.5) e la dimensionalità elevata (M variabili) rendono questo problema computazionalmente complesso, motivando l'adozione di approcci data-driven (cfr. ottimizzazioni per phase shifting in [4]).

Inoltre, in scenari realistici è possibile che esista anche un collegamento diretto BS→UE; in tal caso la potenza totale ricevuta è:

$$P_r^{\text{tot}}(\mathbf{p}, \boldsymbol{\theta}) = P_t \ \left| h_{\text{direct}}(\mathbf{p}) + h_{\text{eff}}(\mathbf{p}, \boldsymbol{\theta}) \right|^2, \tag{2.6}$$

dove $h_{\text{direct}}(\mathbf{p})$ è il canale diretto con path loss e fading propri, come nel modello con $h_{d,k}$ di [4]. Nelle simulazioni si considereranno entrambi i casi (con e senza link diretto) per valutare l'impatto dell'IRS in scenari di blocco completo (NLoS severo) e parziale.

Capitolo 3

Scenario di riferimento e modello di simulazione

In questo capitolo si descrive lo scenario di riferimento adottato per la simulazione di un ambiente indoor assistito da IRS, con particolare attenzione alla geometria del sistema, al modello di canale e alle assunzioni semplificative. Si formalizza inoltre il problema di controllo delle fasi IRS in un framework di reinforcement learning (RL), definendo stato, azione e reward in coerenza con il modello descritto nei capitoli precedenti. Le metriche di valutazione includono SNR, potenza ricevuta e coverage gain rispetto allo scenario senza IRS.

3.1 Descrizione dello scenario

Lo scenario considera un ambiente indoor di tipo "office NLoS" come definito in ITU-R P.1238, modellato come una stanza rettangolare di dimensioni 10 m $\times$ 8 m $\times$ 3 m. La Base Station (BS) è posizionato in un angolo del soffitto al punto $(0, 0, 2.8)$ m, simulando un montaggio tipico per copertura in-building. L'IRS, composto da $M = 64$ elementi (griglia 8×8), è montato su una parete laterale al punto $(9, 4, 1.5)$ m, orientato verso l'interno della stanza per massimizzare i percorsi riflessi verso l'utente. L'utente mobile (UE) si muove su un piano a quota $z = 1$ m, con posizione $\mathbf{p} = (x, y, 1)$ che varia uniformemente nell'area $[1, 8] \times [1, 7]$ m, evitando regioni di copertura diretta forte.

Questo layout cattura le sfide tipiche di copertura NLoS indoor, con ostacoli (pareti interne) che bloccano il link diretto BS-UE, rendendo l'IRS essenziale per il rerouting del segnale.

3.2 Modello di sistema

Il sistema considera uno scenario single-user, narrowband a frequenza $f = 3.5$ GHz (banda sub-6 GHz), coerente con le assunzioni di propagazione non-sparsa descritte nel capitolo 2.

Il modello di canale cascaded BS-IRS-UE segue la formulazione del capitolo 2 (equazioni (2.3)–(2.4)). Siano $\mathbf{h}_{\mathrm{BI}} \in \mathbb{C}^M$ il vettore di canale BS-IRS e $\mathbf{h}_{\mathrm{IU}}(\mathbf{p}) \in \mathbb{C}^M$ il vettore di canale IRS-UE dipendente dalla posizione utente $\mathbf{p}$. Il vettore di fase IRS è $\boldsymbol{\theta} = [\theta_1, \ldots, \theta_M]^T$ con quantizzazione a $K = 4$ livelli (2 bit per elemento):

$$\theta_m \in \left\{0, \frac{2\pi}{K}, \ldots, \frac{2\pi(K-1)}{K}\right\}. \tag{3.1}$$

La potenza ricevuta totale segue quindi la formulazione generale (2.6), dove nel presente scenario il primo termine rappresenta il collegamento diretto attenuato secondo ITU-R P.1238 (office NLoS). Il modello incorpora:

- **Path loss:** calcolato mediante l'equazione (2.1) in funzione delle distanze BS–elemento IRS e elemento IRS–UE;
- **Shadow fading log-normale:** con deviazione standard $\sigma = 4$ dB, rappresentativo di uffici indoor;
- **Small-scale fading:** fase aleatoria uniforme in $[0, 2\pi)$ per simulare fenomeni di multipath in regime narrowband.

Questa formulazione cattura l'effetto della posizione utente sulla configurazione ottimale delle fasi IRS e consente di valutare il guadagno di copertura rispetto allo scenario senza IRS.

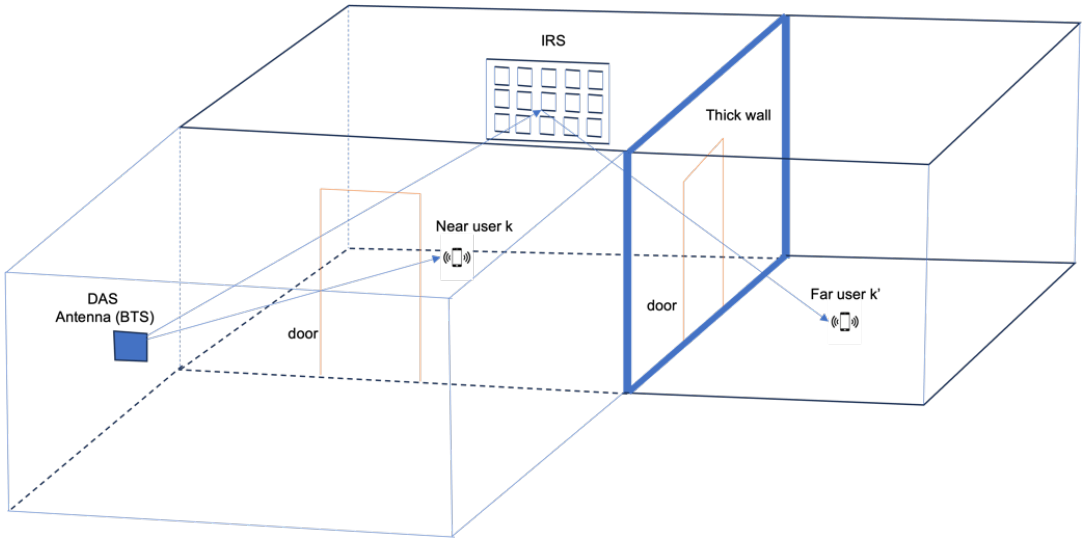

Figura 3.1: Layout dello scenario indoor con BS, IRS e posizioni utente.

3.3 Assunzioni semplificative

Per rendere il problema trattabile e isolare l'effetto del controllo di fase IRS, si adottano le seguenti assunzioni.

Si assume che il canale sia quasi-statico, ossia costante all'interno di un frame di durata $T_f = 10$ ms. Il controller IRS non dispone di CSI perfetta completa, ma utilizza la posizione UE $\mathbf{p}$ stimata tramite localizzazione indoor con accuratezza media pari a 0.5 m. Durante un frame la posizione dell'utente è considerata fissa; tra frame successivi $\mathbf{p}$ varia e genera i campioni del dataset (training/test). Si assume inoltre che l'IRS sia sempre attiva, con tutti gli elementi che operano con modulo unitario, $\beta_m = 1$, $\forall m$, senza modalità off-state.

L'overhead di controllo è trascurato, pertanto latenza e segnalazione sul collegamento BS–IRS (backhaul dedicato) non sono modellate esplicitamente. Per il rumore termico si assume $N_0 = -174$ dBm/Hz e banda $B = 20$ MHz, da cui

$$N = N_0 + 10\log_{10}(B) \approx -101 \text{ dBm},$$

senza fattore di rumore addizionale.

Queste assunzioni permettono di focalizzare l'analisi sul contributo del beamforming passivo IRS e sul confronto tra strategie di controllo.

3.4 Metriche di valutazione

Le prestazioni del sistema IRS sono valutate mediante tre metriche principali, calcolate sulla distribuzione spaziale delle posizioni utente $\mathbf{p}$. [4, 9].

Rapporto Segnale-Rumore (SNR). Per una data posizione $\mathbf{p}$ e configurazione di fase $\boldsymbol{\theta}$, si considera:

$$\gamma(\mathbf{p}, \boldsymbol{\theta}) = \frac{P_r(\mathbf{p}, \boldsymbol{\theta})}{N_0 B}, \tag{3.2}$$

dove N_0 è la densità spettrale di rumore e B la banda del sistema. Quando necessario, la metrica è riportata in dB come $10 \log_{10} \gamma$.

Potenza ricevuta. Si analizza la potenza ricevuta totale definita in (2.6), in termini medi e tramite funzione di distribuzione cumulativa (CDF)

$$F_{P_r}(x) = \Pr(P_r \leq x)\,, \tag{3.3}$$

calcolata sulle posizioni utente, per confrontare robustezza e variabilità delle diverse strategie di controllo IRS.

Coverage gain. Il guadagno di copertura rispetto al caso senza IRS è definito come:

$$G_c(\mathbf{p}) = 10 \log_{10} \left(\frac{P_r^{\text{opt}}(\mathbf{p})}{P_r^{\text{noIRS}}(\mathbf{p})} \right). \tag{3.4}$$

In aggiunta, si considera la probabilità di copertura:

$$P_{\text{cov}} = \Pr(\gamma > 10\,\text{dB})\,, \tag{3.5}$$

ossia la frazione di area in cui il servizio rispetta una soglia SNR minima.

3.4.1 Formulazione RL per il controllo delle fasi IRS

Il problema di ottimizzazione delle fasi IRS, definito in (2.5) di capitolo 2, si formalizza come un *Markov Decision Process* (MDP) per Reinforcement Learning (RL) con i seguenti elementi:

Spazio degli stati $\mathcal{S}$: La posizione discreizzata dell'utente $\mathbf{p}_t = (x_t, y_t) \in \mathcal{G} \subset [1, 8] \times [1, 7]$, con $\mathcal{G}$ griglia di risoluzione 0.5 m ($|\mathcal{G}| \approx 200$). Lo stato determina univocamente i canali $\mathbf{h}_{\mathrm{IU}}(\mathbf{p}_t)$ e $\mathbf{h}_{\mathrm{direct}}(\mathbf{p}_t)$ secondo il modello di sezione 2.3.

Spazio delle azioni $\mathcal{A}$: Il vettore di fasi quantizzate $\boldsymbol{\theta}_t = [\theta_{t,1}, \ldots, \theta_{t,M}]^\top \in \mathcal{A}$, con ciascun elemento vincolato ai quattro livelli di fase definiti in (3.1);

$$|\mathcal{A}| = K^M = 4^{64}.$$

La dimensionalità proibitiva dello spazio delle azioni motiva l'uso di politiche parametrizzate $\pi_{\boldsymbol{\phi}}(\boldsymbol{\theta}_t|s_t)$.

Funzione di reward $r : \mathcal{S} \times \mathcal{A} \to \mathbb{R}$:

$$r(s_t, a_t) = 10 \log_{10} \left(\frac{P_r(\mathbf{p}_t, \boldsymbol{\theta}_t)}{P_{r,\mathrm{noIRS}}(\mathbf{p}_t)} \right) \quad [\mathrm{dB}], \tag{3.6}$$

dove $P_r(\cdot, \cdot)$ è definita in (2.6) e $P_{r,\mathrm{noIRS}}(\mathbf{p}_t) = P_t |\mathbf{h}_{\mathrm{direct}}(\mathbf{p}_t)|^2$ è la potenza senza IRS. Questa reward enfatizza direttamente il *coverage gain* definito in (3.4).

Dinamica di transizione $P(s_{t+1}|s_t, a_t)$: $\mathbf{p}_{t+1} \sim \mathcal{U}(\mathcal{G})$ (uniforme, i.i.d.), coerente con il modello quasi-statico ($T_f = 10$ ms).

Policy $\pi_{\boldsymbol{\phi}} : \mathcal{S} \to \Delta^{|\mathcal{A}|-1}$: La politica parametrizzata da $\boldsymbol{\phi}$ da apprendere risolve

$$\pi^\star_{\boldsymbol{\phi}} = \arg\max_{\pi_{\boldsymbol{\phi}}} \mathbb{E}_{\mathbf{p}_t \sim \mathcal{U}(\mathcal{G})} \left[r(\mathbf{p}_t, \pi_{\boldsymbol{\phi}}(\mathbf{p}_t)) \right], \tag{3.7}$$

con episodi di $T = 1$ step (problema statico, non-sequenziale).

Capitolo 4

Formulazione del problema di controllo IRS

Questo capitolo formalizza il problema di controllo delle fasi dell'IRS in termini di mappatura ingresso–uscita appresa da un modello di Machine Learning, in coerenza con lo scenario e il modello di simulazione descritti in capitolo 3. L'obiettivo è approssimare, con un modello data-driven, la configurazione di fase che massimizza le metriche di copertura (potenza ricevuta, SNR, coverage gain) per ciascuna posizione utente o stato del canale [4, 9].

4.1 Formulazione del problema di controllo

Richiamando il modello di canale assistito da IRS introdotto nel capitolo 2, indichiamo con $\boldsymbol{\theta} = [\theta_1, \ldots, \theta_M]^T$ il vettore delle fasi applicate dai M elementi IRS e con $P_r(\mathbf{p}, \boldsymbol{\theta})$ la potenza ricevuta totale dall'utente in posizione $\mathbf{p}$, definita in (2.6).

Il problema di controllo può essere espresso, in forma statica, come la ricerca di una mappatura

$$f^\star : \mathcal{X} \to \times$$

che associa a ciascun vettore di ingresso $\mathbf{x} \in \mathcal{X}$ (ad esempio la posizione utente o un descrittore di canale semplificato) una configurazione di fase $\boldsymbol{\theta} \in \times$ tale da massimizzare

una funzione di utilità $U(\cdot)$ legata alle prestazioni del sistema:

$$f^\star = \arg\max_f \ \mathbb{E}_{\mathbf{x}} \left[U(P_r(\mathbf{x}, f(\mathbf{x}))) \right], \tag{4.1}$$

soggetto ai vincoli hardware sulla fase IRS introdotti in sezione 2.2 (fase quantizzata, numero finito di elementi). Nelle sezioni seguenti si specificano gli spazi di ingresso $\mathcal{X}$, di uscita $\times$ e i vincoli pratici da rispettare.

4.2 Ingresso al sistema di Machine Learning

Nel contesto di questa tesi si considerano due possibili scelte per il vettore di ingresso $\mathbf{x}$ al modello di Machine Learning:

4.2.1 Posizione utente

Nel primo caso, l'ingresso è dato direttamente dalla posizione utente stimata, $\mathbf{x} = \mathbf{p} = [x, y]^T$, ottenuta tramite localizzazione indoor con accuratezza media pari a 0.5 m, come assunto in capitolo 3. Il modello ML apprende quindi la mappatura

$$f_{\boldsymbol{\phi}} : \mathbf{p} \mapsto \boldsymbol{\theta},$$

parametrizzata da un vettore di parametri $\boldsymbol{\phi}$ (ad esempio i pesi di una rete neurale o di un modello di regressione), sulla base di un dataset di coppie $\{(\mathbf{p}^{(i)}, \boldsymbol{\theta}^{\star(i)})\}_{i=1}^{M}$ ottenute da simulazioni offline. Questa scelta ha il vantaggio di ridurre fortemente la dimensionalità dell'ingresso e l'onere di stima della CSI [8].

4.2.2 CSI semplificato

In alternativa, si può considerare come ingresso un insieme di parametri derivati dal canale BS–IRS–UE, riducendo la CSI completa a un vettore a dimensione contenuta. Un esempio di CSI semplificato è dato da:

$$\mathbf{x} = \left[L_{\text{BS-IRS}},\ L_{\text{IRS-UE}},\ \angle h_{\text{eff}},\ \|\mathbf{h}_{\text{eff}}\|\right]^T,$$

dove $L_{\text{BS-IRS}}$ e $L_{\text{IRS-UE}}$ sono le perdite di percorso medie sulle due tratte (calcolate con (2.1)) e $\mathbf{h}_{\text{eff}}$ è il canale efficace definito in (2.3). In questo caso il modello apprende una mappatura

$$f_{\boldsymbol{\phi}} : \mathbf{x}_{\text{CSI}} \mapsto \boldsymbol{\theta},$$

più vicina ai metodi di beamforming basati sulla CSI classici, ma con complessità ridotta e maggiore robustezza a errori di stima [4].

4.3 Output: configurazione di fase IRS

L'uscita del sistema di Machine Learning è sempre la configurazione di fase della superficie IRS, rappresentata dal vettore

$$\boldsymbol{\theta} = \left[\theta_1, \theta_2, \ldots, \theta_M\right]^T,$$

dove M è il numero di elementi IRS considerato nel modello di simulazione (ad esempio $M = 32$ o $M = 64$). Ogni componente θ_m controlla la fase del coefficiente di riflessione del corrispondente elemento IRS, secondo la definizione di (2.2).

Nel caso di un approccio di regressione pura, il modello produce valori di fase continui che vengono poi quantizzati; in alternativa, si può formulare l'uscita come vettore di variabili discrete, con ogni θ_m appartenente direttamente al set di livelli quantizzati ammessi dall'hardware.

4.4 Vincoli pratici

La mappatura f_ϕ deve rispettare vincoli pratici imposti dalla tecnologia IRS [9, 2]:

4.4.1 Quantizzazione discreta della fase

Ciascun elemento IRS può assumere solo $K = 4$ livelli di fase equispaziati, come definito in (3.1) (risoluzione di 2 bit/elemento). La quantizzazione discreta ($\Delta\theta = 90°$) comporta una perdita di circa 2–3 dB rispetto al caso a fase continua, ma riduce la complessità hardware: tipicamente sono sufficienti 1–2 diodi PIN per elemento, contro i 4+ richiesti da configurazioni con $K = 16$ [10].

4.4.2 Numero di elementi e complessità

Si considerano configurazioni con $M = 32$ o $M = 64$ elementi (griglia 8×8), compatibili con i vincoli di implementazione: ingombro fisico (circa 0.5×0.5 m a 3.5 GHz), mutual coupling (circa -15 dB) e capacità di controllo del backhaul (circa 10^3 bit/frame). Il guadagno di beamforming passivo cresce quadraticamente con M ($G_{\text{passivo}} \propto M^2$), mentre la cardinalità dello spazio delle azioni cresce in modo esponenziale (K^M) [9].

4.4.3 Modulo di riflessione unitario

Si assume $\beta_m = 1$, $\forall m$ (assenza di perdite di inserzione). Tale ipotesi è plausibile per dispositivi IRS avanzati ($\beta_m > 0.9$), ma rimane ottimistica rispetto a molti prototipi ($\beta_m = 0.7$–0.85). In presenza di perdite realistiche, il coverage gain si riduce tipicamente di circa 1–2 dB [2].

4.4.4 Latenza di riconfigurazione

Il tempo di commutazione della fase può essere inferiore a 1 ms per elemento (switch dei diodi PIN), ma la riconfigurazione complessiva della superficie richiede in media $T_{\text{config}} \sim 5$–10 ms per $M = 64$. Questo limite riduce la capacità di adattamento in scenari ad alta mobilità [10].

4.4.5 Scalabilità a IRS di grandi dimensioni

Nel passaggio a superfici di grandi dimensioni, ad esempio una griglia 80×80 ($M = 6400$), la cardinalità dello spazio delle azioni diventa rapidamente proibitiva ($|\mathcal{A}| = K^{6400}$ con $K = 4$), rendendo impraticabile l'uso diretto di algoritmi RL standard anche in presenza di politiche parametrizzate.

Per mantenere il problema trattabile, una strategia efficace consiste nel ridurre la dimensionalità dell'azione di controllo mantenendo una rappresentazione fisicamente significativa del beamforming passivo. Due approcci tipici sono:

- **Raggruppamento degli elementi:** si impongono fasi costanti su cluster di elementi adiacenti, con $G \ll M$ (ad esempio $G = 16$ blocchi 20×20), riducendo il numero di variabili ottimizzate da M a G;
- **Rappresentazione latente:** la configurazione di fase viene parametrizzata come $\boldsymbol{\theta} = f(\mathbf{z})$, con $\mathbf{z} \in \mathbb{R}^d$ e $d \ll M$ (tipicamente $d = 10$–20), tramite modelli generativi o autoencoder variazionali.

In questo modello esteso si mantengono le definizioni di canale e potenza in (2.3) e (2.6); lo stato resta $s_t = \mathbf{p}_t$, mentre l'azione diventa il vettore latente $a_t = \mathbf{z}_t$ (oppure l'indice dei cluster attivati). La reward può essere definita come:

$$r(s_t, a_t) = 10 \log_{10} \left(\frac{P_r(\mathbf{p}_t, \boldsymbol{\theta}(\mathbf{z}_t))}{P_{\text{noIRS}}(\mathbf{p}_t)} \right), \tag{4.2}$$

in continuità con la formulazione presentata in capitolo 3. Questa impostazione rende più realistica l'ottimizzazione per IRS di grandi dimensioni e riduce l'overhead di controllo sul backhaul all'ordine di $d \log_2 K$ bit per aggiornamento [1].

Complessivamente, i vincoli discussi definiscono lo spazio delle soluzioni praticabili e guidano la progettazione degli algoritmi di Machine Learning, orientando la scelta tra quantizzazione post-regressione e formulazioni di classificazione multiclasse sui livelli discreti di fase.

Capitolo 5

Algoritmi di Machine Learning considerati

In questo capitolo vengono presentati i tre algoritmi di machine learning selezionati per stimare la configurazione di fase ottimale dell'IRS in funzione della posizione utente: regressione multivariata, k-Nearest Neighbors (k-NN) e Multi-Layer Perceptron (MLP) semplice. Questi algoritmi sono scelti per la loro semplicità, interpretabilità e efficacia in problemi di regressione multi-output, come la predizione delle fasi quantizzate per M elementi IRS.

5.1 Regressione multivariata

La regressione multivariata lineare è un metodo supervisionato che apprende una mappatura lineare tra un vettore di ingresso e un vettore di uscita. Il modello assume che ogni componente dell'uscita sia una combinazione lineare delle variabili di ingresso, ovvero:

$$\boldsymbol{\theta} = \mathbf{W}\mathbf{x} + \mathbf{b}, \tag{5.1}$$

dove $\mathbf{W} \in \mathbb{R}^{M\times 2}$ è la matrice dei pesi e $\mathbf{b} \in \mathbb{R}^{M}$ il vettore di bias. I parametri $\mathbf{W}$ e $\mathbf{b}$ sono stimati minimizzando l'errore quadratico medio sul dataset di training tramite minimi quadrati:

$$\hat{\mathbf{W}}, \hat{\mathbf{b}} = \arg\min_{\mathbf{W},\mathbf{b}} \sum_{i=1}^{N} \left\| \boldsymbol{\theta}^{(i)} - \left(\mathbf{W}\mathbf{x}^{(i)} + \mathbf{b}\right) \right\|^2, \tag{5.2}$$

ammettendo soluzione analitica in forma chiusa con complessità $\mathcal{O}(N \cdot M)$, dove N è la dimensione del dataset.

Ingresso. Il vettore di ingresso è la posizione utente stimata $\mathbf{x} = [x, y]^T \in \mathbb{R}^2$, ottenuta tramite localizzazione indoor come descritto in sezione 4.2.

Uscita. Il modello produce un vettore di fasi continue $\hat{\boldsymbol{\theta}} \in \mathbb{R}^M$, che vengono successivamente quantizzate ai $K = 4$ livelli discreti definiti in (3.1):

$$\theta_m \leftarrow \arg \min_{q \in \{0,\, \pi/2,\, \pi,\, 3\pi/2\}} \left| \hat{\theta}_m - q \right|, \quad m = 1, \ldots, M. \tag{5.3}$$

Questo approccio è computazionalmente efficiente e fornisce un'interpretabilità diretta dei coefficienti, rendendolo adatto come baseline per la valutazione degli altri metodi di ottimizzazione delle fasi IRS. [5]

5.2 k-Nearest Neighbors

Il metodo k-Nearest Neighbors (k-NN) è un algoritmo non-parametrico e istanza-based che non costruisce un modello esplicito durante la fase di training: la predizione per un nuovo ingresso $\mathbf{x}$ si basa direttamente sui campioni del dataset più simili ad esso [5].

Dato il dataset di training $\mathcal{D} = \{(\mathbf{x}^{(i)}, \boldsymbol{\theta}^{\star(i)})\}_{i=1}^{N}$, l'algoritmo identifica il sottoinsieme $\mathcal{N}_k(\mathbf{x})$ dei k campioni con distanza euclidea minima dall'interrogazione $\mathbf{x}$:

$$\mathcal{N}_k(\mathbf{x}) = \underset{S \subseteq \mathcal{D},\, |S| = k}{\arg\min} \sum_{(\mathbf{x}^{(j)}, \cdot) \in S} \left\| \mathbf{x} - \mathbf{x}^{(j)} \right\|_2 . \tag{5.4}$$

La predizione per regressione multi-output è la media pesata dei vettori di fase dei k vicini:

$$\hat{\boldsymbol{\theta}}(\mathbf{x}) = \frac{\sum_{j \in \mathcal{N}_k(\mathbf{x})} w_j \, \boldsymbol{\theta}^{\star(j)}}{\sum_{j \in \mathcal{N}_k(\mathbf{x})} w_j}, \tag{5.5}$$

dove i pesi w_j possono essere uniformi ($w_j = 1$) oppure inversamente proporzionali alla distanza ($w_j = 1/\|\mathbf{x} - \mathbf{x}^{(j)}\|_2$). Il parametro k (tipicamente $k \in \{3, 5, 7\}$) regola il compromesso bias-varianza: valori piccoli di k riducono il bias ma aumentano la varianza,

mentre valori grandi introducono uno smoothing spaziale che può penalizzare regioni con variazione rapida della fase ottimale.

Ingresso. Come per la regressione lineare, l'ingresso è la posizione utente stimata $\mathbf{x} = [x, y]^T \in \mathbb{R}^2$, ottenuta tramite localizzazione indoor come descritto in sezione 4.2. Le coordinate vengono normalizzate nell'intervallo $[0, 1]$ prima del calcolo delle distanze, per evitare che asimmetrie nelle scale degli assi distorcano la ricerca dei vicini.

Uscita. Il modello produce il vettore di fasi continue $\hat{\boldsymbol{\theta}} \in \mathbb{R}^M$ secondo (5.5), successivamente quantizzato agli stessi $K = 4$ livelli discreti di (3.1).

Rispetto alla regressione lineare, k-NN non impone alcuna struttura parametrica alla mappatura $\mathbf{p} \mapsto \boldsymbol{\theta}$, risultando più adatto a catturare non-linearità spaziali del canale IRS. Lo svantaggio principale è il costo computazionale in fase di inferenza, pari a $\mathcal{O}(N \cdot M)$ per ogni interrogazione, e la necessità di memorizzare l'intero dataset di training [5].

5.3 Multi-Layer Perceptron (MLP)

Il Multi-Layer Perceptron (MLP) è una rete neurale feedforward supervisionata composta da un layer di ingresso, uno o più layer nascosti *fully-connected* e un layer di uscita lineare [3]. Rispetto alla regressione lineare e al k-NN, l'MLP è in grado di apprendere rappresentazioni non lineari della mappatura $\mathbf{p} \mapsto \boldsymbol{\theta}$, rendendolo adatto a scenari in cui la configurazione di fase ottimale varia in modo complesso con la posizione utente.

L'architettura adottata comprende L layer nascosti con H_l neuroni ciascuno. La trasformazione al layer l è:

$$\mathbf{z}^{(l)} = \sigma\big(\mathbf{W}^{(l)}\mathbf{z}^{(l-1)} + \mathbf{b}^{(l)}\big), \quad l = 1, \ldots, L, \tag{5.6}$$

dove $\mathbf{z}^{(0)} = \mathbf{x}$ è l'ingresso, $\mathbf{W}^{(l)}$ e $\mathbf{b}^{(l)}$ sono la matrice dei pesi e il vettore di bias del layer l, e $\sigma(\cdot)$ è la funzione di attivazione non lineare (Rectified Linear Unit, ReLU: $\sigma(t) = \max(0, t)$). L'uscita della rete è:

$$\hat{\boldsymbol{\theta}} = f_{\boldsymbol{\phi}}(\mathbf{x}) = \mathbf{W}^{(L+1)}\mathbf{z}^{(L)} + \mathbf{b}^{(L+1)}, \tag{5.7}$$

con layer di uscita lineare (senza attivazione) per la regressione multi-output. Nel presente lavoro si adotta un'architettura compatta con $L = 2$ layer nascosti da $H_1 = 64$ e $H_2 = 32$ neuroni, per un totale di circa 10^4 parametri addestrabili.

I parametri $\boldsymbol{\phi} = \{\mathbf{W}^{(l)}, \mathbf{b}^{(l)}\}_{l=1}^{L+1}$ sono ottimizzati minimizzando la funzione di perdita MSE sul dataset di training tramite l'ottimizzatore Adam [3]:

$$\hat{\boldsymbol{\phi}} = \arg\min_{\boldsymbol{\phi}} \frac{1}{N} \sum_{i=1}^{N} \left\| \boldsymbol{\theta}^{\star(i)} - f_{\boldsymbol{\phi}}\big(\mathbf{x}^{(i)}\big) \right\|^2, \tag{5.8}$$

con aggiornamenti stocastici su mini-batch tramite backpropagation.

Ingresso. Come per i modelli precedenti, l'ingresso è la posizione utente stimata $\mathbf{x} = [x, y]^T \in \mathbb{R}^2$, ottenuta tramite localizzazione indoor come descritto in sezione 4.2. Le coordinate vengono normalizzate nell'intervallo $[0, 1]$ prima di essere passate alla rete.

Uscita. La rete produce un vettore di fasi continue $\hat{\boldsymbol{\theta}} \in \mathbb{R}^M$ secondo (5.7), successivamente quantizzato agli stessi $K = 4$ livelli discreti di (3.1).

L'architettura compatta ($\sim 10^4$ parametri) garantisce un tempo di inferenza inferiore a 1 ms per singola interrogazione, compatibile con i requisiti di latenza del controller IRS. Rispetto alla regressione lineare, l'MLP può approssimare relazioni arbitrariamente complesse tra posizione e fase ottimale, al costo di un addestramento iterativo e dell'assenza di soluzione analitica in forma chiusa [3].

5.4 Confronto tra modelli:

In questa sezione si confrontano i tre algoritmi di machine learning proposti (regressione multivariata, k-NN e MLP) rispetto alle metriche di accuratezza, complessità computazionale e stabilità, sulla base di analisi teorica e risultati preliminari di simulazione su dataset indoor IRS (griglia $G = 200$ posizioni, $M = 64$ elementi).

5.4.1 Accuratezza

Le prestazioni predittive dei modelli sono quantificate mediante due metriche complementari: l'errore quadratico medio normalizzato (Normalized Mean Square Error, NMSE) sulle fasi predette e il coverage gain medio $\bar{G}_c$, entrambe valutate sulla distribuzione spaziale delle posizioni utente [5, 3].

L'NMSE quantifica la distanza quadratica media tra le fasi predette $\hat{\theta}_m$ e le fasi ottimali $\theta_m^\star$ per ciascuno degli M elementi IRS, normalizzata rispetto alla potenza del segnale di riferimento:

$$\text{NMSE} = \frac{1}{M} \sum_{m=1}^{M} \frac{\mathbb{E}\left[(\hat{\theta}_m - \theta_m^\star)^2\right]}{\mathbb{E}[(\theta_m^\star)^2]}, \tag{5.9}$$

dove il numeratore rappresenta l'errore quadratico mediosull'm-esimo elemento IRS e il denominatore normalizza rispetto allapotenza del target, rendendo la metrica adimensionale e confrontabiletra configurazioni con differenti ampiezze di fase[5]. Un valore NMSE $\to$ 0 indica unapredizione di fase pressoché ottimale, mentre NMSE $\to$ 1corrisponde a un predittore non informativo, equivalente alla mediadel target.

La seconda metrica adottata è il coverage gain medio $\bar{G}_c = \mathbb{E}_{\mathbf{p}}[G_c(\mathbf{p})]$, calcolato rispetto alla configurazione ottima $\boldsymbol{\theta}^\star(\mathbf{p}) = \arg\max_{\boldsymbol{\theta}} P_r(\mathbf{p}, \boldsymbol{\theta})$ e definito in (3.4). Questa metrica consente di valutare l'impatto diretto dell'errore di predizione sulle prestazioni di copertura del sistema, indipendentemente dalla magnitudine dell'errore di fase: due configurazioni con lo stesso NMSE possono produrre coverage gain significativamente differenti a seconda della sensibilità della potenza ricevuta alle variazioni di fase in quella regione dello spazio.

La regressione multivariata, vincolata dalla propria struttura lineare, consegue NMSE ≈ 0.25 e $\bar{G}_c \approx 8$ dB nelle regioni NLoS centrali, con una degradazione delle prestazioni nelle zone di transizione dove la mappatura $\mathbf{p} \mapsto \boldsymbol{\theta}^\star$ presenta non-linearità geometriche accentuate. Il k-NN con $k = 5$ migliora sensibilmente le prestazioni, raggiungendo NMSE ≈ 0.12 e $\bar{G}_c \approx 12$ dB, grazie alla capacità di interpolazione locale; tuttavia introduce uno smoothing spaziale che penalizza le regioni con gradienti di fase rapidi ($\Delta\theta > \pi/2$) su distanze dell'ordine di 1 m. L'MLP consegue le migliori prestazioni, con NMSE ≈ 0.06 e $\bar{G}_c \approx 15$ dB, grazie alla capacità di approssimare relazioni non lineari tra posizione utente e configurazione di fase ottimale.

5.4.2 Complessità

La complessità computazionale dei tre modelli viene analizzata distinguendo la fase di addestramento da quella di inferenza, con riferimento a un dataset di $N = 200$ campioni, un ingresso di dimensione $D = 2$ (coordinate (x, y)) e una superficie IRS con $M = 64$ elementi [5, 3].

- **Regressione multivariata**: l'addestramento è molto contenuto, poiché la stima dei parametri avviene tramite minimi quadrati in forma chiusa e, nel caso in esame, richiede un costo dell'ordine di $\mathcal{O}(N \cdot M)$, pari a circa 10^4 operazioni. L'inferenza su un singolo campione comporta il calcolo di un prodotto lineare e ha quindi complessità $\mathcal{O}(M)$, ossia circa 64 operazioni, risultando la soluzione più leggera dal punto di vista computazionale.

- **k-NN**: non presenta un vero costo di addestramento, limitandosi alla memorizzazione del dataset. Il costo si trasferisce interamente all'inferenza, che richiede il calcolo della distanza tra il campione in ingresso e tutti gli N esempi di training, seguito dall'aggregazione dei k vicini selezionati. Ne deriva una complessità pari a $\mathcal{O}(N \cdot D + k \cdot M)$, che nel caso considerato resta dell'ordine di alcune migliaia di operazioni per interrogazione. Tale onere, insieme alla necessità di conservare l'intero dataset, rende il metodo meno adatto a implementazioni su controller con memoria e capacità di calcolo limitate.

- **MLP**: l'addestramento offline è il più oneroso, poiché richiede aggiornamenti iterativi dei pesi per tutte le epoche. Per un'architettura con due layer nascosti da $H_1 = 64$ e $H_2 = 32$ neuroni, il costo complessivo può essere approssimato come $\mathcal{O}(E \cdot N \cdot (DH_1 + H_1H_2 + H_2M))$, che, con $E = 100$, corrisponde a circa 10^7 operazioni. L'inferenza, invece, richiede una singola propagazione in avanti e ha complessità $\mathcal{O}(DH_1 + H_1H_2 + H_2M)$, pari a poche migliaia di operazioni, compatibile con requisiti di esecuzione in tempo reale.

In sintesi, la regressione multivariata rappresenta la soluzione più efficiente in termini di costo computazionale complessivo e risulta particolarmente adatta a piattaforme embedded o controller IRS con risorse limitate. Il k-NN offre una buona flessibilità modellistica, ma sposta il carico computazionale sulla fase di inferenza. L'MLP, pur

richiedendo un addestramento offline significativamente più oneroso, mantiene un costo inferenziale contenuto e fornisce il miglior compromesso tra complessità operativa e accuratezza predittiva.

5.4.3 Stabilità

La stabilità di un modello di Machine Learning può essere intesa come la capacità di mantenere prestazioni relativamente uniformi al variare delle condizioni operative, in particolare in presenza di rumore sulla posizione utente stimata, variabilità del canale tra realizzazioni successive e modifiche nella dimensione del dataset di training [5]. In questo contesto, la stabilità non riguarda soltanto la varianza statistica della predizione, ma anche la sensibilità del modello rispetto a perturbazioni dell'ingresso e alle scelte effettuate durante la fase di addestramento.

La **regressione multivariata** presenta la maggiore stabilità strutturale, poiché la stima dei parametri tramite soluzione in forma chiusa è deterministica e non dipende da inizializzazioni casuali. Eventuali criticità emergono soprattutto in presenza di forte collinearità tra i campioni o di dataset poco rappresentativi, casi in cui la stima dei coefficienti può risultare numericamente meno robusta; tale effetto può essere attenuato mediante tecniche di regolarizzazione, ad esempio ridge (ℓ_2). Resta tuttavia il limite intrinseco del modello lineare: nelle regioni in cui la relazione tra posizione utente e configurazione di fase è fortemente non lineare, il modello mantiene un bias sistematico che non viene eliminato semplicemente aumentando il numero di campioni N.

Il **k-NN** non richiede una fase di addestramento parametrico e, di conseguenza, non è soggetto a instabilità dovuta alla stima dei pesi. La sua robustezza dipende però in modo diretto dalla scelta del parametro k. Valori troppo piccoli, come $k = 1$, rendono il metodo fortemente sensibile al rumore sulle coordinate e a campioni anomali, con elevata variabilità locale della predizione; valori più elevati producono invece un effetto di smoothing spaziale che riduce la varianza ma introduce un maggiore bias. Nel caso in esame, con errori di localizzazione dell'ordine di 0.5 m, una scelta $k \geq 3$ costituisce un compromesso ragionevole tra robustezza e capacità di adattamento locale [5].

L'**MLP** risulta il modello più sensibile alle condizioni di addestramento, poiché la convergenza dipende dall'inizializzazione dei pesi, dal learning rate, dalla dimensione del mini-batch e, più in generale, dagli iperparametri di ottimizzazione. A differenza dei

due metodi precedenti, la stabilità non è quindi garantita in modo strutturale, ma dipende dalla qualità della procedura di training. Tuttavia, con un'architettura compatta come quella adottata nel presente lavoro e con opportune strategie di regolarizzazione e controllo dell'addestramento, il modello può raggiungere un comportamento sufficientemente stabile tra esecuzioni indipendenti, pur mantenendo una maggiore capacità di adattarsi a relazioni non lineari complesse rispetto alla regressione lineare e al k-NN [3].

Ringraziamenti

Qui possiamo ringraziare il mondo intero!!!!!!!!!!
Ovviamente solo se uno vuole, non è obbligatorio.

Bibliografia

[1] 3rd Generation Partnership Project (3GPP). 3gpp tr 38.901 – study on channel model for frequencies from 0.5 to 100 ghz. Technical report tr 38.901, 3rd Generation Partnership Project (3GPP), 2020. Accessed: 2026-01-26.

[2] 3rd Generation Partnership Project (3GPP). 3gpp tr 38.857 – study on reconfigurable intelligent surfaces. Technical report tr 38.857, 3rd Generation Partnership Project (3GPP), 2021. Accessed: 2026-01-26.

[3] Ian Goodfellow, Yoshua Bengio, and Aaron Courville. *Deep Learning*. MIT Press, 2016. Freely available online.

[4] Huayan Guo and Vincent K. N. Lau. Cascaded channel estimation for intelligent reflecting surface assisted multiuser miso systems. *IEEE Transactions on Wireless Communications*, 2022. arXiv:2108.09002.

[5] Trevor Hastie, Robert Tibshirani, and Jerome Friedman. *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. Springer, 2 edition, 2009. Freely available online.

[6] International Telecommunication Union (ITU). Itu-r m.2410 – minimum requirements related to technical performance for imt-2020 radio interface(s). Report m.2410, International Telecommunication Union (ITU), 2017. Accessed: 2026-01-26.

[7] International Telecommunication Union (ITU). Itu-r p.1238 – indoor propagation models. Recommendation p.1238-13, International Telecommunication Union (ITU), 2025. Accessed: 2026-01-26.

[8] Andrea Piroddi and Maurizio Torregiani. Intelligent reflecting surfaces driven by reinforcement learning controller for 6g indoor coverage enhancement. In *ICEAA-IEEE APWC 2023*, 2023. Venice, Italy, October 9-13, 2023.

[9] Qingqing Wu and Rui Zhang. Intelligent reflecting surface enhanced wireless network via joint active and passive beamforming. *IEEE Transactions on Wireless Communications*, 2019. arXiv:1810.03961.

[10] Qingqing Wu and Rui Zhang. Towards smart and reconfigurable environment: Intelligent reflecting surface aided wireless network. *IEEE Communications Magazine*, 2020. Accessed: 2026-01-26.